


LAPORAN TEKNIS KOMPREHENSIF

BurnoutLens

Capstone Project
CC26-PSU352



DAFTAR ISI

1.	Analisis Permasalahan dan Solusi.....	3
1.1.	Latar Belakang	3
1.2.	Root Cause dan Solusi Utama.....	4
2.	Rumusan Pertanyaan Bisnis (SMART Framework)	5
3.	Data Wrangling	6
3.1.	Gathering Data	6
3.2.	Asessing Data	7
3.3.	Cleaning Data	8
4.	Synthetic Data Generation.....	10
4.1.	Statistik Anchor per Level	10
4.2.	Stratified Sampling Anchor dan Loop Simulasi.....	10
4.3.	Validasi dan Hasil.....	11
5.	Exploratory Data Analysis (EDA)	12
5.1.	EDA Dataset NLP Emosi.....	12
5.2.	EDA Dataset Burnout	13
5.3.	EDA Data Synthetic Time-Series.....	15
6.	Feature Engineering	17
6.1.	Fitur Baru Dataset Burnout (6 Fitur)	17
6.2.	Fitur Kontekstual Dataset Synthetic (7 Fitur LSTM)	18
6.3.	Sliding Window dan Scalling.....	18
7.	A/B Testing: Strategi Threshold Peringatan Dini	20
7.1.	Setup Kedua Versi & Hipotesis.....	20
7.2.	Hasil Metrik.....	20
7.3.	Uji Statistik.....	21
7.4.	Analisis Tingkat User	21
8.	Kesimpulan dan Rekomendasi Action	23
8.1.	Ringkasan Temuan Utama	23
8.2.	Jawaban Business Question (Ringkasan).....	24
8.3.	Rekomendasi Action Item.....	25
9.	Referensi	27

1. Analisis Permasalahan dan Solusi

1.1.Latar Belakang

Kesehatan mental pekerja di Indonesia saat ini berada dalam kondisi yang mengkhawatirkan. Proyek BurnoutLens lahir dari identifikasi 5 permasalahan utama yang terdokumentasi secara ilmiah dan berdampak langsung pada produktivitas serta kesejahteraan pekerja.

a. Burnout sudah menjadi krisis nasional.

Data riset Fakultas Kedokteran Universitas Indonesia (FKUI) menunjukkan bahwa 83% tenaga kesehatan di Indonesia mengalami gejala burnout tingkat sedang hingga berat selama pandemi [1]. Fenomena ini tidak lagi terbatas pada sektor kesehatan, tetapi meluas ke berbagai sektor pekerjaan.

b. Burnout tidak terdeteksi sampai terlambat.

Mayoritas individu baru menyadari kondisi burnout setelah mencapai tahap kronis, ditandai penurunan produktivitas drastis, memburuknya hubungan interpersonal, atau transisi ke fase depresi klinis. Belum tersedia sistem peringatan dini yang mampu memberikan sinyal sebelum kondisi memburuk.

c. Tidak ada platform pemantau emosi harian yang terintegrasi.

Aplikasi jurnal harian, pemantau tidur, dan manajemen produktivitas saat ini beroperasi secara terfragmentasi. Ketiadaan platform tunggal yang menghubungkan variabel-variabel ini menyulitkan pengguna mendapatkan gambaran kondisi mental yang utuh dan komprehensif.

d. Stigma dan keterbatasan akses ke professional.

Menurut laporan WHO (2022), di negara berpenghasilan rendah dan menengah, diperkirakan lebih dari 75% orang dengan gangguan mental tidak menerima pengobatan sama sekali [2]. Di Indonesia, stigma sosial yang kuat menjadi penghalang utama bagi pekerja untuk mencari bantuan professional.

e. Fragmentasi data: emosi dan aktivitas fisik belum terintegrasi.

Riset dalam bidang *Affective Computing* membuktikan bahwa pendekatan multimodal, menggabungkan teks dan data perilaku, memberikan akurasi prediksi kondisi mental yang jauh lebih tinggi [3]. Namun data kualitatif (teks jurnal) dan kuantitatif (jam tidur & kerja) selama ini tersimpan terpisah dan tidak pernah dianalisis bersamaan.

1.2.Root Cause dan Solusi Utama

Akar masalah utama yang teridentifikasi adalah: individu tidak memiliki cara untuk memantau kondisi mentalnya sendiri secara proaktif, objektif, dan berbasis data.

Input Data	Cara Analisis	Output
Teks Jurnal Harian	Model NLP (Natural Language Processing)	Klasifikasi emosi & mood score
Jam Tidur & Jam Kerja Harian	Model LSTM (Long Short-Term Memory): Time-Series	Prediksi skor burnout harian

Alasan Solusi tersebut dipilih:

- Preventif, Bukan Reaktif: Sistem memberikan peringatan dini sebelum burnout mencapai tahap kronis.
- Mandiri dan Privat: Pengguna memantau kondisi mental kapan saja tanpa berhadapan dengan stigma sosial.
- Berbasis Data Riil: Menggunakan kombinasi data kebiasaan nyata (tidur & kerja) dan ekspresi emosi (jurnal).
- Skalabel: Platform berbasis web yang dapat menjangkau jutaan pengguna secara efisien.

2. Rumusan Pertanyaan Bisnis (SMART Framework)

Pertanyaan bisnis dirumuskan menggunakan kerangka SMART (*Specific, Measurable, Action-oriented, Relevant, Time-bound*). Setiap pertanyaan diturunkan langsung dari permasalahan yang telah diidentifikasi dan memiliki metrik keberhasilan yang terukur.

No.	Domain	Business Question	Kategori
BQ-1	NLP	Bagaimana distribusi kelas emosi pada data training NLP dan seberapa parah ketimpangannya?	Anomali
BQ-2	NLP	Seberapa besar kontribusi tiap sumber dataset dan sumber mana yang paling dominan?	Anomali
BQ-3	NLP	Bagaimana distribusi panjang teks dan berapa nilai optimal max_length untuk tokenizer?	Pola
BQ-4	Burnout	Seberapa kuat dan ke arah mana hubungan antara jam tidur dan skor burnout?	Hubungan
BQ-5	Burnout	Fitur mana yang lebih berpengaruh terhadap burnout dan seberapa besar selisihnya?	Prediksi
BQ-6	Burnout	Bagaimana rata-rata jam kerja, jam tidur, dan burnout score berbeda antar level?	Kategorisasi
BQ-7	Burnout	Seberapa parah imbalance dan perbandingannya setelah Synthetic Data Generation?	Kategorisasi
BQ-8	Burnout	Seberapa kuat hubungan antar fitur dan mana yang paling independen?	Hubungan
BQ-9	Synthetic	Pada hari ke berapa burnout melewati threshold Moderate dan High dalam 30 hari?	Pola
BQ-10	Synthetic	Sejauh mana distribusi synthetic mencerminkan karakteristik anchor level asli?	Pola

3. Data Wrangling

Data Wrangling adalah proses mempersiapkan data mentah agar siap untuk analisis dan pemodelan. Proses ini dilakukan melalui tiga tahap berurutan: Gathering → Assessing → Cleaning.

3.1. Gathering Data

Proyek ini mengelola dua kluster data dengan tujuan berbeda: Korpus NLP untuk klasifikasi emosi teks dan Dataset Burnout untuk prediksi skor burnout berbasis time-series.

Dataset	Sumber	Jumlah Baris	Peran
Twitter Emotion Dataset	Kaggle	4.401	Dataset NLP utama berbahasa Indonesia
Ricco48 (5 file emosi)	GitHub	5.079	Pengaya emosi spesifik per kelas
IndoNLU (train/valid/test)	GitHub	4.401	Benchmark NLP standar Indonesia
English Emotion Archive	Kaggle	19.281	Augmentasi data (diterjemahkan ke Bahasa Indonesia)
kamus_singkatan.csv	GitHub	1.309	Normalisasi singkatan teks Indonesia
tech_mental_health_burnout	Kaggle	150.000	Basis EDA & Synthetic Data Generation

Total Korpus NLP sebelum cleaning = **33.162 baris** dari 4 sumber. Dataset English mendominasi volume (~58%), sementara tiga sumber Indonesia berkontribusi relatif seimbang masing-masing ~13-15%. Dataset burnout menghasilkan **150.000 baris** data tabular pekerja teknologi.

3.2. Asessing Data

Evaluasi kualitas dan struktur masing-masing dataset dilakukan sebelum cleaning. Aspek yang diperiksa meliputi: *missing values*, duplikat, tipe data, distribusi label, dan outlier.

Dataset	Missing	Duplikat	Isu Utama	Penanganan
kamus_singkatan	0	67 (1 baris + 66 key)	Satu singkatan = banyak terjemahan	keep='first'
Twitter	0	11	Noise teks, imbalance 1.73:1	Hapus + clean_text
Ricco48	0	43	Label kapital, nama tidak seragam	Mapping + dedup
IndoNLU	0	7	Minimal, format sudah konsisten	Hapus duplikat
English	0	42 + 719 surprise	Imbalance parah 4.12:1, Bahasa Inggris	Terjemahkan + dedup
Burnout	0	0	Class imbalance EKSTREM High=0.04%	Synthetic Data Generation

Temuan Kritis Burnout Dataset: Kelas **High** hanya memiliki **65 baris dari 150.000** (0.04%), dengan rasio Low:High mencapai **2.308:1**. Ini adalah class imbalance yang sangat ekstrem: model apapun yang dilatih langsung pada data ini akan mengabaikan kelas High sepenuhnya. Ironisnya, kelas High adalah yang paling kritis untuk dideteksi dalam konteks kesehatan mental. Solusi: Synthetic Data Generation.

3.3.Cleaning Data

Proses cleaning terdiri dari tiga sub-tahap utama yang diterapkan secara berurutan pada setiap dataset.

Fungsi <code>clean_text()</code> : Pipeline Pembersihan Teks NLP	Pipeline 7 langkah berurutan: (1) Lowercase, (2) Normalisasi singkatan via KAMUS_DICT, (3) Hapus URL, (4) Hapus mention & hashtag, (5) Hapus angka, (6) Hapus karakter non-huruf, (7) Rapikan spasi ganda. Diterapkan konsisten di semua 4 sumber dataset NLP.
Terjemahan English Dataset	Seluruh 19.281 teks diterjemahkan ke Bahasa Indonesia menggunakan GoogleTranslator dengan mekanisme: retry otomatis 5x saat error, checkpoint setiap 500 baris untuk toleransi terputusnya sesi. Makna emosi tetap terjaga dengan baik (contoh: "hopeless" → "putus asa", "grouchy" → "kesal").
Penggabungan & Safety Pass NLP	Keempat dataset digabung (32.913 baris), lalu <code>clean_text</code> diterapkan sekali lagi ke seluruh korpus untuk menangkap duplikat lintas-sumber: dua teks dari sumber berbeda yang identik setelah cleaning. Hasilnya 934 baris terhapus (32.913 → 31.979). Dua assert dijalankan sebagai gerbang kualitas.
Cleaning Burnout Dataset	<code>work_hours_per_week</code> + <code>overtime_hours</code> digabung menjadi <code>total_work_hours_per_week</code> . 21 kolom tidak relevan di-drop, menyisakan 4 kolom: <code>total_work_hours_per_week</code> , <code>sleep_hours</code> , <code>burnout_score</code> , <code>burnout_level</code> . Shape final: (150.000 × 4).

Hasil Akhir Cleaning: nlp_emotion_final.csv → 31.979 baris × 2 kolom (tweet_clean, label) | burnout_cleaned.csv → 150.000 baris × 4 kolom. Distribusi kelas NLP final: happy (30.28%), sadness (26.65%), anger (23.06%), fear (9.09%), love (10.92%): rasio imbalance 2.77:1.

4. Synthetic Data Generation

Dataset burnout bersifat *cross-sectional*: setiap baris hanya merepresentasikan satu *snapshot* kondisi seorang pekerja pada satu titik waktu, bukan rekaman harian. Sementara itu, model LSTM membutuhkan data sekuensial (*time-series*) yang merekam perubahan kondisi dari hari ke hari.

Setelah pencarian menyeluruh di sumber publik, tidak ditemukan dataset yang memiliki kombinasi *work_hours* harian, *sleep_hours* harian, dan *burnout_score* harian dalam satu tabel. Dataset *time-series* dibangun sendiri menggunakan dataset burnout asli sebagai *anchor* (titik awal simulasi per user). Data synthetic ini bukan data nyata, artinya dibuat berdasarkan statistik dan pola dari data asli.

4.1. Statistik Anchor per Level

Statistik berikut dihitung dari data asli untuk dijadikan dasar logika simulasi memastikan data synthetic mencerminkan pola nyata, bukan angka acak.

Level	Jam Kerja/ Minggu	Jam Tidur/ Malam	Burnout Score	Burnout Score Max
Low	52.06	6.54	1.82 (mean)	≤ 3.5
Moderate	60.84	6.22	4.25 (mean)	3.6 - 6.5
High	69.12	5.66	6.89 (mean)	≥ 6.6

- a) Setiap naik satu level: jam kerja naik ~ 8.5 jam/minggu, jam tidur turun ~ 0.4 jam/malam.
- b) Batas antar level tidak tumpang tindih $\rightarrow$ digunakan sebagai threshold simulasi.
- c) Threshold simulasi: $\text{THRESH_BURNOUT_MOD} = 3.6$,
 $\text{THRESH_BURNOUT_HI} = 6.6$, $\text{THRESH_WORK_HEAVY} = 12$ jam/hari.

4.2. Stratified Sampling Anchor dan Loop Simulasi

Stratified Sampling: Semua 65 data High diambil seluruhnya (kelas minoritas paling kritis), sementara Moderate dan Low masing-masing 500 sampel acak. Total 1.065 anchor user disimulasikan selama 30 hari.

Kondisi	Efek pada Burnout Score
Kerja > 12 jam/hari	Tidur berkurang + consecutive_overwork naik

Lembur ≥ 3 hari berturut-turut	Burnout naik +0.2–0.5 poin/hari (dampak kumulatif terkuat)
Kerja < 10.4 jam DAN tidur > 6.54 jam	Burnout turun (kondisi recovery)
Semua nilai	Dijaga dalam batas wajar dengan np.clip

4.3. Validasi dan Hasil

Dua kondisi wajib diverifikasi untuk memastikan data synthetic logis secara domain:

- work_hours harus berkorelasi positif dengan burnout $\rightarrow$ terpenuhi ($r = +0.531$).
- sleep_hours harus berkorelasi negatif dengan burnout $\rightarrow$ terpenuhi ($r = -0.763$).
- Sanity check: 0 pelanggaran batas nilai (work < 4 jam, sleep < 3 jam, burnout < 1 atau > 10).

File Output	Shape	Isi
synthetic_timeseries_daily.csv	31.950×8	Data harian per user: untuk EDA & FE
lstm_meta.csv	24.495 baris	Metadata sliding window (user_id, predict_day, anchor_level)

Hasil Synthetic Data Generation: Distribusi burnout_level setelah simulasi: High 40.0%, Moderate 29.3%, Low 30.7%. Rasio imbalance turun dari 2.308:1 $\rightarrow$ ~1.4:1. Kelas High yang sebelumnya hanya 65 baris kini memiliki 12.781 sampel: cukup untuk model LSTM mempelajari pola burnout berat secara bermakna.

5. Exploratory Data Analysis (EDA)

5.1. EDA Dataset NLP Emosi

a. BQ-1: Distribusi Kelas Emosi

Distribusi kelas emosi pada dataset NLP final menunjukkan ketimpangan yang perlu ditangani saat pelatihan model.

Emosi	Jumlah	Persentase	Vs. Ideal (20%)
happy	9.668	30.28%	+10.28% (di atas ideal)
sadness	8.511	26.65%	+6.65% (di atas ideal)
anger	7.365	23.06%	+3.06% (di atas ideal)
love	3.487	10.92%	-9.08% (di bawah ideal)
fear	2.948	9.09%	-10.91% (di bawah ideal)

Insight BQ-1: Rasio imbalance 2.77:1 (happy vs love). Penyebab utama: dominasi English Archive yang happy-heavy (35.1%) pada korpus gabungan. Tergolong imbalance sedang → ditangani dengan `class_weight='balanced'` saat training agar kelas minoritas (fear, love) mendapat bobot proporsional lebih tinggi.

b. BQ-2: Kontribusi Setiap Sumber Dataset

Sumber	Baris	Proporsi	Karakteristik Distribusi
English (Translated)	~19.108	~60%	happy paling dominan (35.1%), love hanya 8.5%
Ricco48	~4.989	~16%	Paling seimbang: tidak ada kelas yang terlalu mendominasi
IndoNLU	~4.382	~14%	Anger tertinggi (25%), distribusi merata di 5 kelas
Twitter	~4.348	~14%	Distribusi mirip IndoNLU: keduanya dari medsos Indonesia

Insight BQ-2: English Archive mendominasi volume (60%) dan merupakan sumber utama ketimpangan happy di korpus final. Ketiga sumber Indonesia menunjukkan distribusi yang relatif merata: menjadi fondasi yang lebih seimbang untuk training model.

- c. BQ-3: Distribusi Panjang Teks & max_length Tokenizer
- a) Median: 18 kata per teks: mayoritas tweet relatif pendek dan padat.
 - b) P95: 41 kata → direkomendasikan sebagai max_length tokenizer (95% teks tidak terpotong).
 - c) Maksimum: 352 kata (outlier dari English: kalimat panjang), std = 11.47.
 - d) Panjang teks relatif seragam antar kelas emosi → model tidak akan bias berdasarkan panjang teks

Insight BQ-3: Gunakan max_length = 41 pada tokenizer NLP agar 95% teks dapat direpresentasikan penuh tanpa pemotongan, sementara 5% teks ekstrem panjang dipotong untuk efisiensi komputasi.

5.2.EDA Dataset Burnout

- a. BQ-4: Hubungan Jam Tidur vs Burnout Score

Uji korelasi Pearson menunjukkan hubungan negatif signifikan antara jam tidur dan burnout score ($r = -0.1331$, $p \approx 0.000$). Namun kekuatannya tergolong lemah secara praktis.

- a) $r = -0.1331$, $p \approx 0.000$ → negatif signifikan, lemah secara praktis.
- b) Dengan 150.000 sampel, hampir semua korelasi otomatis signifikan (statistical power sangat tinggi).
- c) Threshold peringatan dini: tidur ≤ 6.2 jam/malam (rata-rata jam tidur gabungan Moderate + High).
- d) Scatter plot menunjukkan persebaran titik yang sangat lebar: sleep_hours saja tidak cukup.

Insight BQ-4: Jam tidur berpengaruh negatif terhadap burnout, namun pengaruhnya lemah. Faktor jam kerja jauh lebih menentukan (dibuktikan pada BQ-5). Sleep_hours tetap dipertahankan sebagai fitur pendukung karena kombinasinya dengan jam kerja (dual_risk_flag) terbukti kuat.

- b. BQ-5: Fitur Dominan terhadap Burnout Score

Fitur	Korelasi Pearson	Arah	Signifikansi
total_work_hours_per_week	0.4922	Positif ↑	$p \approx 0.000$
sleep_hours	0.1331	Negatif ↓	$p \approx 0.000$

Insight BQ-5: total_work_hours_per_week $3.7\times$ lebih kuat ($|r| = 0.492$) dibanding sleep_hours ($|r| = 0.133$). Beban kerja adalah prediktor burnout yang dominan. Scatter plot work_hours vs burnout menunjukkan tren positif yang jauh lebih jelas: kepadatan titik data bergeser ke atas seiring bertambahnya jam kerja

c. BQ-6: Rata-rata Fitur per Burnout Level

Level	Jam Kerja/ Minggu	Jam Tidur/ Malam	Burnout Score (mean)
Low	52.06	6.54	1.82
Moderate	60.84	6.22	4.25
High	69.12	5.66	6.89
Selisih per level	+8.5 jam ↑	-0.4 jam ↓	Monoton naik

Insight BQ-6: Pola monoton yang sangat jelas dan konsisten: setiap naik satu level, jam kerja naik ~ 8.5 jam/minggu dan jam tidur turun ~ 0.4 jam/malam. Batas antar level tidak tumpang tindih $\rightarrow$ Low ≤ 3.5 , Moderate 3.6–6.5, High ≥ 6.6 .

d. BQ-7: Class Imbalance: Sebelum vs Sesudah Synthetic

Level	Data Asli	Setelah Synthetic
Low	87.75% (131.620 baris)	30.7% (~ 9.807 baris)
Moderate	12.21% (18.315 baris)	29.3% (~ 9.352 baris)
High	0.04% (65 baris)	40.0% (~ 12.781 baris)
Rasio Imbalance	2.025:1 (Low vs High)	$\sim 1.4:1$

Insight BQ-7: Kelas High dari hanya 65 baris kini memiliki 12.781 sampel. Rasio imbalance turun drastis dari 2.025:1 menjadi ~1.4:1. High sedikit mendominasi (40%) pada synthetic: disengaja agar model sensitif terhadap burnout berat.

e. BQ-8: Korelasi Antar Fitur (Independensi)

- a) work_hours vs sleep_hours: $r \approx 0.004 \rightarrow$ hampir tidak berkorelasi = saling independen.
- b) sleep_deficit = $8 - \text{sleep_hours} \rightarrow$ korelasi -1.0 dengan sleep_hours (transformasi linear sempurna).
- c) Kedua fitur utama tidak redundan dan masing-masing membawa informasi independen.
- d) Justifikasi: aman menggunakan keduanya sekaligus sebagai input model tanpa risiko multikolinearitas.

Insight BQ-8: sleep_hours dihapus dari fitur input LSTM karena sleep_deficit ($= 8 - \text{sleep_hours}$) adalah transformasi linear sempurna yang lebih interpretatif ("kurang berapa jam dari standar WHO"), sehingga keduanya membawa informasi identik.

5.3.EDA Data Synthetic Time-Series

a. BQ-9: Tren Burnout 30 Hari: Kapan Melewati Threshold?

Rata-rata burnout score seluruh user dianalisis per hari selama simulasi 30 hari.

- a) Threshold Moderate (36) dilewati di hari ke-3 simulasi.
- b) Threshold High (66) dilewati di hari ke-21 simulasi.
- c) Lembur ≥ 3 hari berturut-turut mendorong burnout naik +41.4 poin dibanding tanpa lembur.
- d) Tren per kelompok anchor: grup High langsung mulai di ~70 dan cepat mendekati maksimum (100).

Insight BQ-9: Dasar Trigger Notifikasi: consecutive_overwork ≥ 3 hari berbasis data (bukan arbitrer) ditetapkan sebagai threshold trigger notifikasi BurnoutLens. Rata-rata burnout saat overwork=0 adalah 37.4, sedangkan saat overwork ≥ 3 adalah 78.9: selisih +41.4 poin atau lebih dari 2 $\times$ lipat.

b. BQ-10: Validasi Distribusi Synthetic vs Anchor Asli

Anchor Level	Jam Kerja/Hari (mean)	Jam Tidur (mean)	Burnout Score (mean)	Consec. Overwork (mean)
Low	10.58	5.64	38.03	3.65
Moderate	12.22	4.78	70.17	6.73
High	13.86	4.00	91.47	10.02

Insight BQ-10: Distribusi terbedakan jelas per level: selisih mean burnout: Low → Moderate +32.1 poin, Moderate → High +21.3 poin. Semua fitur menunjukkan pola monoton yang konsisten. Synthetic berhasil merepresentasikan karakteristik anchor.

6. Feature Engineering

Feature Engineering bertujuan mengekstrak informasi yang lebih kaya dari fitur mentah berdasarkan temuan EDA, sehingga model dapat belajar pola yang lebih kompleks dan diskriminatif antar level burnout.

6.1. Fitur Baru Dataset Burnout (6 Fitur)

Semua threshold berbasis data dari hasil EDA: bukan nilai arbitrer.

Fitur Baru	Jenis	Formula/Treshold	Dasar (EDA)
work_hours_per_day	Numerik	total_work / 5	Konversi ke satuan harian
work_rest_ratio	Numerik	work / (24 – work – sleep), cap p99	Tekanan waktu harian
sleep_deficit	Numerik	8 – sleep_hours	Defisit vs standar WHO
overwork_flag	Biner	1 jika kerja > 10.4 jam/hari	BQ-3 (threshold Low)
sleep_risk_flag	Biner	1 jika tidur <= 6.2 jam/malam	BQ-4 (rata-rata Mod+High)
dual_risk_flag	Biner	1 jika overwork DAN sleep_risk	Sinyal kombinasi terkuat

Distribusi Flag per Burnout Level (memvalidasi diskriminasi diskriminasi fitur)

Level	% Overwork	% Sleep Risk	% Dual Risk
Low	47.7%	40.5%	18.8%
Moderate	86.0%	51.3%	43.5%
High	100%	63.1%	63.1%

Insight FE Burnout: Semua user High mengalami overwork (100%). dual_risk_flag melonjak drastis: 18.8% (Low) menjadi 43.5% (Moderate) menjadi 63.1% (High): kenaikan paling tajam = fitur biner dengan diskriminasi level terbaik.

6.2. Fitur Kontekstual Dataset Synthetic (7 Fitur LSTM)

Tujuh fitur kontekstual harian ditambahkan ke dataset synthetic untuk memperkaya representasi time-series yang akan dipelajari model LSTM.

Fitur	Jenis	Deskripsi & Catatan Teknis
sleep_deficit	Numerik	Defisit tidur harian vs standar WHO
work_rest_ratio	Numerik	Rasio kerja:istirahat harian, cap p99 = 16.51
rolling_burnout_7d	Numerik	Rata-rata burnout 7 hari sebelumnya per user. shift(1) sebelum rolling() untuk mencegah data leakage
burnout_delta	Numerik	Perubahan burnout dari hari sebelumnya (diff). Positif = memburuk
overwork_flag	Biner	1 jika kerja > 10.4 jam/hari
dual_risk_flag	Biner	1 jika overwork DAN sleep_risk aktif bersamaan
work_hours_per_day	Numerik	Jam kerja harian (fitur asli yang dipertahankan)

Feature Selection: sleep_hours dihapus karena sleep_deficit = 8 - sleep_hours adalah transformasi linear sempurna (korelasi = -1.0) menjadi informasi identik. sleep_risk_flag juga dihapus karena informasinya sudah tercakup dalam dual_risk_flag: memasukkan ketiganya sekaligus berisiko multikolinearitas

6.3. Sliding Window dan Scalling

- Sliding Window: Setiap 7 hari berturutan dijadikan satu sampel input (X) untuk memprediksi hari ke-8 (y). Shape X_fe_arr: (24.495, 7, 7): 24.495 sampel x 7 hari x 7 fitur.
- Split: 80% train / 10% val / 10% test = 19.596 / 2.449 / 2.450 sampel.- MinMaxScaler: fit() HANYA pada data train (anti-leakage), transform() ke train + val + test. Range [0.0, 1.0].

- c. Scaler disimpan sebagai `scaler_fe.pkl`: wajib di-load ulang saat inferensi agar skala konsisten.

Perbandingan Sebelum vs Sesudah Feature Engineering: Sebelum: 2 fitur mentah (`work_hours` + `sleep_hours`), shape (24.495, 7, 2). Sesudah: 7 fitur kaya konteks, shape (24.495, 7, 7). Semua assertion lolos: 0 NaN, 0 data leakage, scaling [0.0, 1.0].

7. A/B Testing: Strategi Threshold Peringatan Dini

Sistem peringatan dini BurnoutLens membutuhkan keputusan desain yang kritis: pada threshold berapa sistem harus memicu notifikasi kepada pengguna? Threshold terlalu tinggi melewatkan banyak kasus burnout (false negative), sementara terlalu rendah membanjiri pengguna dengan notifikasi tidak relevan (false positive).

Eksperimen ini merupakan simulasi perbandingan strategi threshold menggunakan data sintetis. Kedua versi dievaluasi pada dataset yang sama: bukan kelompok pengguna nyata yang terpisah. Pendekatan ini dipilih karena data pengguna real belum tersedia pada tahap pengembangan produk, namun secara statistik tetap valid untuk membandingkan performa dua kebijakan sistem.

7.1. Setup Kedua Versi & Hipotesis

Aspek	Versi A: Konservatif	Versi B: Agresif
Threshold	burnout_score $\geq$ 66	burnout_score $\geq$ 36
Level Diberi Peringatan	High saja	Moderate + High
Filosofi	Hanya peringatan yang sudah kritis	Deteksi dini sebelum kritis
Jumlah Peringatan	12.844 (40.2% observasi)	21.968 (68.8% observasi)

- Hipotesis Chi-Square (H_0): Tidak ada perbedaan proporsi prediksi benar antara Versi A dan B.
- Hipotesis Z-Test (H_0): Tidak ada perbedaan Recall antara Versi A dan B.
- Metrik utama: Recall dipilih karena melewatkan burnout (False Negative) jauh lebih berbahaya dari False Positive.
- Alpha: 0.05 untuk kedua uji.

7.2. Hasil Metrik

Metrik	Versi A: Konservatif	Versi B: Agresif	Selisih
Precision	1.0000	0.9698	-0.0302
Recall	0.5708	0.9468	+0.3760
F1-Score	0.7268	0.9582	+0.2314

FPR (False Positive Rate)	0.0000	0.0702	+0.0702
Accuracy	0.6977	0.9418	+0.2441

Perbedaan Kritis: Versi A hanya mendeteksi 57% kasus berisiko: artinya 9.658 observasi berisiko tidak mendapat peringatan sama sekali. Versi B berhasil mendeteksi 94.7% kasus berisiko dengan trade-off FPR 7%: dari 9.448 observasi tidak berisiko, hanya ~663 mendapat peringatan yang tidak perlu.

7.3. Uji Statistik

Uji	Statistik	p-value	Keputusan
Chi-Square (proporsi prediksi benar)	$\chi^2 = 6.438,68$	$p \approx 0.000$	Tolak H_0
Z-Test Proporsi (Recall)	$z = -93.23$	$p \approx 0.000$	Tolak H_0

Versi	Recall	95% Confidence Interval
A: Konservatif	0.5708	[0.5643: 0.5773]
B: Agresif	0.9468	[0.9439: 0.9497]

Interpretasi CI: Kedua interval tidak tumpang tindih sama sekali: batas atas CI Versi A (0.5773) jauh di bawah batas bawah CI Versi B (0.9439), jarak 0.3666 poin. Ini membuktikan perbedaan Recall bukan sekadar signifikan secara statistik, tetapi juga signifikan secara praktis.

7.4. Analisis Tingkat User

Keterangan	Versi A: Konservatif	Versi B: Agresif
Total user pernah berisiko	916 user	916 user
User terdeteksi (≥ 1 peringatan)	782 user (85.4%)	916 user (100%)

User terlewat (missed)	134 user	0 user
------------------------	----------	--------

Rekomendasi Final: PILIH VERSI B (threshold ≥ 36): Dalam konteks kesehatan mental, Recall adalah metrik yang paling kritis. Versi B berhasil mendeteksi 100% dari 916 user berisiko (0 terlewat), sementara Versi A melewatkan 134 pengguna yang tidak pernah mendapat peringatan sepanjang 30 hari simulasi. Trade-off FPR sebesar 7% jauh lebih dapat diterima dibanding risiko melewatkan kasus burnout berat yang berpotensi berkembang ke depresi klinis.

8. Kesimpulan dan Rekomendasi Action

8.1. Ringkasan Temuan Utama

Data dan Pipeline	BurnoutLens berhasil mengintegrasikan dua domain data: 33.162 teks emosi dari 4 sumber (NLP) dan 150.000 data pekerja teknologi (burnout). Pipeline menghasilkan: 31.979 sampel NLP bersih, 31.950 baris synthetic time-series, dan 24.495 sampel LSTM (7 hari x 7 fitur).
Prediktor Burnout	Beban kerja adalah prediktor burnout yang dominan ($r = +0.492$), bukan jam tidur ($r = -0.133$). Fitur <code>dual_risk_flag</code> (overwork + sleep risk) merupakan sinyal biner terkuat: melonjak dari 18.8% (Low) ke 63.1% (High). Seluruh user High mengalami overwork (100%).
Synthetic Data	Class imbalance ekstrem (High hanya 0.04%) berhasil diatasi. Rasio imbalance turun dari 2.025:1 menjadi $\sim 1.4:1$. Validasi korelasi dan sanity check semua lolos. Distribusi synthetic terbedakan jelas per level anchor.
A/B Testing	Threshold agresif ≥ 36 (Versi B) jauh lebih tepat: Recall 0.9468 vs 0.5708, F1 0.9582 vs 0.7268. Versi B mendeteksi 100% dari 916 user berisiko. Kedua uji statistik menolak H_0 (p sekitar 0.000). CI tidak tumpang tindih menjadi perbedaan signifikan secara statistik DAN praktis.
Early Warning	Burnout rata-rata melewati threshold Moderate di hari ke-3, High di hari ke-21. Trigger notifikasi: <code>consecutive_overwork</code> ≥ 3 hari berbasis data. Lembur berturut-turut selama 3+ hari rata-rata menaikkan burnout lebih dari 2x lipat (+41.4 poin).

8.2. Jawaban Business Question (Ringkasan)

BQ	Jawaban Terukur
BQ-1	Rasio imbalance 2.77:1 (happy vs love) menjadi tangani dengan <code>class_weight='balanced'</code>
BQ-2	English Archive mendominasi (60%): sumber utama ketimpangan happy (35.1%)
BQ-3	Median 18 kata, P95 = 41 kata menjadi gunakan <code>max_length = 41</code> pada tokenizer
BQ-4	$r = -0.133$ (lemah, signifikan) menjadi threshold peringatan dini: tidur ≤ 6.2 jam/malam
BQ-5	<code>work_hours</code> 3.7x lebih kuat dari <code>sleep_hours</code> menjadi beban kerja adalah prediktor dominan
BQ-6	Per level: jam kerja naik ~ 8.5 jam/minggu, jam tidur turun ~ 0.4 jam/malam
BQ-7	Sebelum: 2.025:1 menjadi sesudah synthetic: $\sim 1.4:1$, High dari 65 menjadi 12.781 sampel
BQ-8	r sekitar 0.004 (work vs sleep) menjadi independen, aman digunakan bersama dalam model
BQ-9	Moderate di hari ke-3, High di hari ke-21, trigger: <code>consecutive_overwork</code> ≥ 3 hari
BQ-10	Low ke Moderate +32.1 poin, Moderate ke High +21.3 poin, distribusi terbedakan jelas

8.3.Rekomendasi Action Item

Berdasarkan seluruh temuan proyek, berikut adalah rekomendasi tindak lanjut yang dapat diimplementasikan dalam berbagai jangka waktu.

Jangka Pendek (0 - 3 bulan)
a. Implementasikan sistem notifikasi berbasis threshold B (≥ 36) pada aplikasi BurnoutLens. b. Aktifkan trigger consecutive_overwork ≥ 3 hari sebagai sinyal peringatan dini otomatis. c. Validasi model NLP dan LSTM pada data pengguna nyata: mulai dari kelompok kecil (beta testing). d. Load scaler_fe.pkl saat inferensi untuk memastikan konsistensi skala dengan da
Jangka Menengah (3 - 12 bulan)
a. Integrasikan output NLP (mood score dari jurnal teks) dengan prediksi LSTM sebagai sistem multimodal yang lebih akurat. b. Kembangkan UI mobile-friendly: pengguna input jam kerja & tidur harian, terima notifikasi peringatan dini otomatis. c. Lakukan A/B Testing dengan pengguna nyata untuk validasi threshold yang direkomendasikan. d. Tambahkan fitur rujukan ke psikolog/konselor jika burnout_level terdeteksi High selama ≥ 3 hari berturut-turut.
Jangka Panjang (12+ bulan)
a. Bangun Dataset Time-Series Nyata: kumpulkan data pengguna nyata dari aplikasi untuk melatih ulang model dengan data aktual. b. Kembangkan Dashboard HR (anonim) untuk memantau tren burnout tim tanpa melanggar privasi individu. c. Implementasikan enkripsi end-to-end dan data minimization: hanya simpan data yang diperlukan untuk prediksi. d. Perluas ke bahasa daerah Indonesia untuk menjangkau populasi yang lebih luas.

- e. Jalin kemitraan dengan perusahaan untuk validasi eksternal dan skalabilitas platform.

BurnoutLens membuktikan bahwa deteksi dini burnout berbasis AI adalah sebuah kemungkinan yang realistis. Dengan menggabungkan ekspresi emosi (NLP) dan data perilaku harian (LSTM), sistem ini berpotensi menjadi alat preventif yang bermakna bagi kesehatan mental jutaan pekerja Indonesia: khususnya mereka yang tidak memiliki akses mudah ke profesional kesehatan mental

9. Referensi

- [1] Soemarko, D. S., Basrowi, R. W., et al. (2022). Prevalence and Determinant Factors of Health Workers Burnout during COVID-19 Pandemic in Indonesia. *Safety and Health at Work*.
- [2] World Health Organization. (2022). *World Mental Health Report: Transforming Mental Health for All*. Geneva: WHO.
- [3] Guntuku, S. V., et al. (2017). Detecting depression and mental illness on social media: an integrative review. *Current Opinion in Behavioral Sciences*, 18, 43–49.
- [4] International Labour Organization. (2016). *Workplace Stress: A collective challenge*. Geneva: ILO.
- [5] Maslach, C., & Leiter, M. P. (2016). Understanding the burnout experience: recent research and its implications for psychiatry. *World Psychiatry*, 15(2), 103–111.
- [6] Hochreiter, S., & Schmidhuber, J. (1997). Long Short-Term Memory. *Neural Computation*, 9(8), 1735–1780.
- [7] National Sleep Foundation. (2015). *Sleep Duration Recommendations*. [Sleepfoundation.org](https://www.sleepfoundation.org).
- [8] Thelwall, M., et al. (2010). Sentiment in Twitter events. *Journal of the American Society for Information Science and Technology*.
- [9] Dataset: tech_mental_health_burnout: Kaggle (2024).
- [10] Dataset: Twitter Emotion Dataset: Kaggle (2023). Indonesian emotion tweets.
- [11] Dataset: IndoNLU Indonesian Emotion: GitHub (EmoSet-ISM).
- [12] Dataset: English Emotion: Kaggle (dair-ai/emotion).
- [13] Dataset: Ricco48 Emotion: GitHub (repo kelas emosi bahasa Indonesia).